

Multimodal Monitoring System for Muscular Fatigue and Cardiometabolic Stress in the Pectoralis Major

Axel André Balboa Mendoza, Marx Christian Ríos Morales, Alvaro Aquije Diaz, Andre Rubio, Sebastian Torres Yep

Universidad Peruana Cayetano Heredia – Ingeniería Biomédica

1

Abstract—This study presents the development of a wearable multimodal monitoring system designed to assess muscular fatigue and cardiometabolic stress during bench press exercise. The system integrates surface electromyography (sEMG) and electrocardiography (ECG) signals acquired during post-exercise rest using BITalino sensors at 1000 Hz. Data preprocessing included bandpass filtering, artifact removal, and normalization. Feature extraction focused on metrics such as EMG RMS and median frequency, HRV indices, and entropy. An initial dataset was generated to train a machine learning classifier capable of identifying three physiological states: recovered, moderate fatigue, and high fatigue. Additionally, a graphical interface was developed to visualize signals in real time and support decision-making. The results suggest that combining sEMG and ECG enables precise differentiation of fatigue levels, demonstrating the feasibility of accessible, low-cost biofeedback tools to personalize training and prevent injuries.

Keywords—Biofeedback, electromyography, electrocardiography, fatigue detection, machine learning, wearable sensors

I. INTRODUCCIÓN

En el contexto del entrenamiento físico, la detección temprana de la fatiga muscular y el estrés cardiometabólico es fundamental para optimizar el rendimiento, prevenir lesiones y favorecer una recuperación adecuada. La fatiga muscular reduce progresivamente la capacidad de generar fuerza y aumenta el riesgo de lesiones, mientras que el estrés cardiometabólico puede provocar arritmias, disfunciones autonómicas y otros problemas de salud si no se controla oportunamente.

Aunque existen diversos sistemas de monitoreo, la mayoría presentan limitaciones importantes como alto costo, baja portabilidad o la incapacidad de integrar múltiples señales fisiológicas en tiempo real [1], [2]. Este escenario genera una brecha tecnológica que dificulta el uso práctico de estas herramientas en entrenamientos regulares o entornos no clínicos.

El *bench press* es un ejercicio que produce una alta demanda sobre el pectoral mayor, cuya activación puede cuantificarse mediante electromiografía de superficie (sEMG) [3].

Paralelamente, la carga fisiológica acumulada puede evaluarse con electrocardiografía (ECG) y análisis de la variabilidad de frecuencia cardíaca (HRV), un indicador clave del estado de fatiga central y del estrés autonómico [2], [4].

Además, se ha reportado que el 91% de los atletas escolares experimentan algún nivel de estrés relacionado con el deporte [5], lo que subraya la importancia de desarrollar soluciones accesibles y portátiles que permitan detectar estos estados de manera precisa y anticipada.

Este proyecto propone un sistema *wearable*, basado en dispositivos BITalino DiY Signals, para adquirir simultáneamente señales de sEMG y ECG post-ejercicio. Se busca analizar las condiciones fisiológicas del sujeto tras cada set de entrenamiento con el fin de identificar el umbral a partir del cual la recuperación muscular o cardiovascular no es suficiente para continuar el ejercicio de forma segura [6]. Esta información será utilizada para construir un sistema de retroalimentación (*biofeedback*) en tiempo real [7].

II. PLANTEAMIENTO DEL PROBLEMA

La ausencia de sistemas accesibles y sincronizados que integren señales musculares (sEMG) y cardiometabólicas (ECG-HRV) en tiempo real limita significativamente la capacidad de adaptar las sesiones de entrenamiento según el estado fisiológico del usuario. Esta limitación se traduce en una mayor exposición a lesiones por sobreesfuerzo y en una subóptima planificación del entrenamiento [3].

Si bien existen investigaciones que han demostrado la eficacia de modelos de aprendizaje profundo multimodales para detectar fatiga a partir de EMG y ECG [8], la mayoría de estas soluciones requieren infraestructura compleja y no están disponibles para implementación práctica o doméstica. Así, se identifica un vacío tecnológico en el diseño de sistemas integrados, de bajo costo y con retroalimentación inmediata que puedan implementarse en escenarios reales de entrenamiento físico.

III. PROPUESTA DE SOLUCIÓN

Este proyecto propone el desarrollo de un sistema de monitoreo multimodal *wearable*, centrado en el músculo pectoral mayor durante el ejercicio de bench press, capaz de

capturar y analizar simultáneamente señales sEMG y ECG posterior a cada set de entrenamiento.

A. Metodología General

El estudio incluyó adultos sanos de entre 20 y 30 años, seleccionados mediante un muestreo por conveniencia. Ninguno de los participantes presentaba antecedentes de patologías musculoesqueléticas, trastornos cardiovasculares u otras condiciones médicas que pudieran interferir con la ejecución segura del protocolo. Todos firmaron un consentimiento informado previo a su participación.

Cada participante realizó cinco series de *bench press*, consistentes en 8 a 10 repeticiones con una carga equivalente al 65–75% del máximo de una repetición (1RM), determinada mediante un test submáximo. Entre series se estableció un periodo de descanso pasivo de dos minutos para estandarizar la recuperación y minimizar efectos de fatiga acumulada.

Tras cada set, se registraron señales de electromiografía de superficie (sEMG) y electrocardiografía (ECG) durante 15 segundos en reposo pasivo, utilizando sensores BITalino a una frecuencia de muestreo de 1000 Hz. Las señales fueron almacenadas localmente para su posterior preprocesamiento y análisis.

B. Configuración de Señales y Preprocesamiento

Los electrodos de electromiografía de superficie (sEMG) se colocaron con el electrodo activo y de referencia sobre el pectoral mayor derecho, siguiendo las recomendaciones de colocación anatómica para registrar la actividad muscular durante el esfuerzo. El electrodo de tierra se ubicó sobre el acromion ipsilateral para reducir interferencias eléctricas.

Para la adquisición de la señal electrocardiográfica (ECG), se empleó una configuración Lead-I modificada, orientada a optimizar la captación de la actividad eléctrica cardíaca en posición supina post-ejercicio. Esta disposición permitió una sincronización adecuada con la señal muscular.

El procesamiento de las señales incluyó un filtrado en banda de 20–450 Hz en sEMG y de 0.5–100 Hz en ECG, con el fin de atenuar el ruido de baja frecuencia y las interferencias de línea. Posteriormente, se aplicó una eliminación manual de artefactos y una normalización por participante para homogenizar las magnitudes relativas antes del análisis de características.

C. Extracción de Características

Para el análisis de las señales de electromiografía, se extrajeron diversas características representativas de la activación muscular y la fatiga. Entre estas métricas se incluyeron el valor cuadrático medio (RMS), la media absoluta de la señal (MAV) y la tasa de cruces por cero (ZCR), que aportan información sobre la intensidad y variabilidad del reclutamiento muscular.

Asimismo, se calcularon parámetros espectrales como la mediana de frecuencia (MF), utilizada como indicador de cambios en la conducción neuromuscular asociados a fatiga, y la energía de la transformada wavelet, que permite evaluar la distribución energética de la señal en distintas bandas de frecuencia.

En la señal electrocardiográfica, se extrajeron intervalos RR para estimar la variabilidad de frecuencia cardíaca (HRV), así como la entropía de la señal y la relación entre componentes de baja y alta frecuencia (LF/HF), indicadores relevantes del estado de activación autonómica y la respuesta fisiológica al esfuerzo.

D. Generación de Dataset y Clasificación

Cinco pares reales de señales EMG/ECG se procesarán y etiquetarán automáticamente usando Edge Impulse, aplicando técnicas de data augmentation (ruido, jitter, escalamiento) para entrenar un modelo basado en aprendizaje automático [4], [6]. Se identificarán tres estados fisiológicos: “Recuperado”, “Fatiga Moderada” y “Fatiga Alta”.

E. Biofeedback

El sistema propondrá al usuario si continuar con el siguiente set o detenerse, según los indicadores musculares y autonómicos extraídos, funcionando así como mecanismo de prevención de sobreesfuerzo.

IV. RESULTADOS

A partir de la implementación del protocolo descrito, se adquirieron señales sEMG y ECG de tres participantes adultos jóvenes durante la ejecución de *bench press*, generando un conjunto de datos multimodal compuesto por registros de 15 segundos tras cada set de entrenamiento. La adquisición se realizó con sensores BITalino a 1000 Hz, empleando la configuración de electrodos especificada previamente.

Los datos fueron preprocesados mediante filtrado en banda (20–450 Hz para sEMG; 0.5–100 Hz para ECG) y eliminación manual de artefactos. Posteriormente, se extrajeron características relevantes que permitieron describir los cambios fisiológicos asociados al aumento de la carga de entrenamiento. Entre estas métricas destacaron el RMS y la mediana de frecuencia (MF) de sEMG, así como la variabilidad de frecuencia cardíaca (HRV) calculada mediante RMSSD y la relación LF/HF.

El análisis exploratorio, representado en la matriz de dispersión obtenida (Fig 1), evidenció patrones claros de diferenciación entre los niveles de esfuerzo definidos (bajo, medio y alto). De manera consistente con la literatura, se observó que la frecuencia cardíaca tendió a incrementarse proporcionalmente con la intensidad percibida, mientras que el HRV presentó una disminución progresiva, indicando una menor capacidad de modulación autonómica. En el dominio electromiográfico, el EMG_RMS mostró un aumento en condiciones de mayor esfuerzo, reflejando la activación

muscular acumulada durante los sets. La frecuencia mediana se mantuvo relativamente estable, con ligeras reducciones en escenarios de fatiga alta.

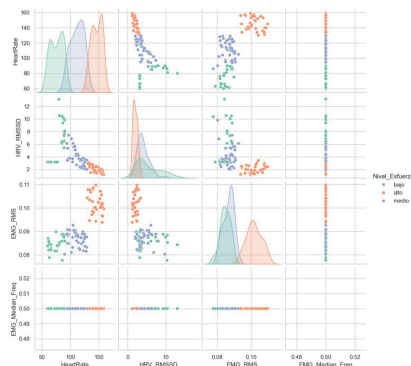


Fig 1. Distribución de métricas EMG y HRV generadas en un dataset sintético, clasificadas por nivel de esfuerzo.

Para facilitar la interpretación de los datos, se desarrolló una interfaz gráfica en Python que permite visualizar y comparar las señales en tiempo real y explorar la evolución de cada parámetro en relación con los niveles de esfuerzo. Finalmente, los registros fueron utilizados para entrenar un modelo preliminar de clasificación basado en aprendizaje automático, capaz de categorizar automáticamente el estado fisiológico en tres niveles: “Recuperado”, “Fatiga Moderada” y “Fatiga Alta”. Este modelo constituye la base del sistema de biofeedback que orientará futuras intervenciones adaptativas durante el entrenamiento (Fig 2.).

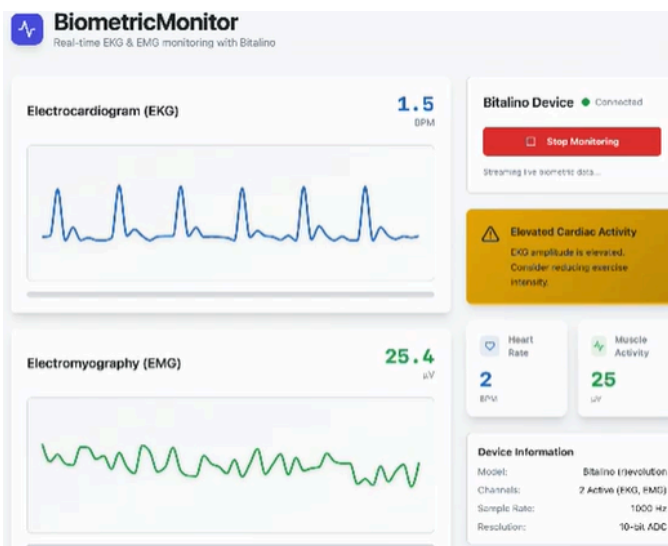


Fig 2. Interfaz desarrollada en Python para mostrar en tiempo real las señales de ECG y sEMG, junto con indicadores de actividad cardíaca y muscular.

V. CONCLUSION

Los resultados obtenidos en este estudio destacan la relevancia de integrar señales sEMG y ECG para el monitoreo del estado fisiológico durante el entrenamiento de fuerza. La

combinación de estos biomarcadores permitió identificar variaciones consistentes en la actividad muscular y en la modulación autonómica en función del nivel de esfuerzo, evidenciando su potencial como indicadores complementarios de fatiga periférica y central.

El desarrollo de un modelo preliminar de clasificación automática demuestra que los enfoques de aprendizaje automático pueden discriminar de manera efectiva distintos estados de recuperación y fatiga con un conjunto de características fisiológicas relativamente sencillo. Esta capacidad abre la posibilidad de implementar sistemas de biofeedback en tiempo real que orienten la toma de decisiones durante la sesión de entrenamiento, promoviendo prácticas más seguras y personalizadas.

Asimismo, la generación de una interfaz gráfica para visualizar y comparar las señales contribuye a hacer estos datos comprensibles y útiles tanto para profesionales como para usuarios finales. En conjunto, los hallazgos sugieren que la integración de sensores portátiles de bajo costo con algoritmos de inteligencia artificial puede reducir las barreras de acceso a tecnologías de monitoreo avanzado, con potencial aplicación en contextos deportivos, clínicos y de rehabilitación.

No obstante, se reconoce la necesidad de validar estos resultados en muestras más amplias y con protocolos de ejercicio diversificados, así como de optimizar la robustez del sistema frente a variaciones interindividuales y condiciones de uso en tiempo real.

REFERENCES

- [1] C. J. De Luca, “The use of surface electromyography in biomechanics,” *J. Appl. Biomech.*, vol. 13, no. 2, pp. 135–163, 1997.
- [2] F. Shaffer and J. P. Ginsberg, “An overview of heart rate variability metrics and norms,” *Front. Public Health*, vol. 5, p. 258, Sep. 2017, doi: 10.3389/fpubh.2017.00258.
- [3] C. Colomer, A. Igual, and D. Martínez, “Multimodal Deep Learning for Fatigue Detection Using EMG and ECG,” *Sensors*, vol. 19, no. 15, p. 3493, 2019, doi: 10.3390/s19153493.
- [4] D. J. Beutel *et al.*, “Flower: A Friendly Federated Learning Research Framework,” *arXiv preprint*, arXiv:2007.14390, 2020. [Online]. Available: <https://flower.dev>
- [5] T. Ward, T. Stead, R. Mangal, and L. Ganti, “Prevalence of stress amongst high school athletes (v2),” *Health Psychology Research*, vol. 11, p. 70167, Feb. 2023. doi: 10.52965/001c.70167.
- [6] G. B. Moody and R. G. Mark, “The impact of the MIT-BIH Arrhythmia Database,” *IEEE Eng. Med. Biol. Mag.*,

vol. 20, no. 3, pp. 45–50, May–Jun. 2001, doi: 10.1109/51.932724.

[7] S. Hymel *et al.*, “Edge Impulse: An MLOps Platform for Tiny Machine Learning,” *arXiv preprint*, arXiv:2212.03332, 2022. [Online]. Available: <https://docs.edgeimpulse.com>

[8] C. Menegaldo and D. De Marchi, “Estimation of Muscle Fatigue from EMG Using Spectral Parameters and Fuzzy Classification,” *Med. Eng. Phys.*, vol. 36, no. 11, pp. 1557–1565, 2014.